

Pipeline de detección de personas

De Roboflow al modelo embarcado para búsqueda y rescate

Guardian Eye

TFG - Ingeniería de Tecnologías de Telecomunicación, UC3M

Nerea Gorostidi Garcia

1. Visión general del pipeline

El sistema completo tiene dos partes claramente separadas, que conviene distinguir desde el principio porque se ejecutan en momentos y lugares distintos:

Fase	Dónde ocurre	Qué se hace
1. Construcción del dataset	Roboflow (en la nube)	Reunir, unificar y etiquetar imágenes de personas vistas desde el aire
2. Entrenamiento del modelo	Roboflow (en la nube)	Enseñar a una red neuronal (YOLO) a reconocer personas a partir del dataset
3. Exportación y compilación	Roboflow → herramienta del fabricante del acelerador (en tu PC)	Convertir el modelo entrenado a un formato que el dispositivo embarcado pueda ejecutar a velocidad útil
4. Inferencia (uso real)	A bordo del dron, en vuelo	El dron aplica el modelo ya entrenado sobre lo que ve la cámara, en tiempo real, sin conexión a internet ni a Roboflow

Esta distinción es importante: Roboflow interviene solo en las fases 1-3 (todo lo que ocurre antes de volar). Una vez el modelo está compilado y cargado en el dron, este vuela y detecta personas de forma completamente autónoma.

2. Conceptos clave antes de empezar

2.1 ¿Qué es OpenCV?

OpenCV (Open Source Computer Vision Library) es una librería de software, gratuita y muy usada, para trabajar con imágenes y vídeo mediante código. No es un modelo de IA en sí mismo — es la "caja de herramientas" que se usa alrededor del modelo: capturar el vídeo de la cámara fotograma a fotograma, cambiarle el tamaño o el formato antes de pasarlo al modelo, y dibujar los recuadros de detección (bounding boxes) sobre la imagen una vez el modelo ha dicho dónde están las personas detectadas.

2.2 ¿Qué es YOLO?

YOLO (You Only Look Once) es una familia de arquitecturas de red neuronal especializada en detección de objetos: dada una imagen, no solo dice "hay una persona", sino exactamente dónde está (con un rectángulo delimitador, o bounding box) y con qué confianza. Analiza la imagen completa en una sola pasada por la red, por eso es rápido, y por eso es la familia de modelos estándar para detección en tiempo real (vídeo), como es este caso.

2.3 Aceleración embarcada (concepto general)

El procesador de un ordenador de a bordo de propósito general (por ejemplo, una Raspberry Pi) puede ejecutar un modelo YOLO, pero lentamente. Para procesar vídeo en vuelo a velocidad útil, suele hacer falta un acelerador dedicado (un NPU — Neural Processing Unit, o una GPU embebida), un chip diseñado específicamente para ejecutar redes neuronales de forma mucho más rápida y con

menor consumo. Esta guía no asume una marca de acelerador concreta — adapta esta sección al hardware exacto de tu proyecto (el paso de "compilar el modelo para el dispositivo" cambia de herramienta según el fabricante, pero el concepto es el mismo).

2.4 ¿Qué son Gazebo y ROS?

Gazebo es un simulador de robótica 3D: reproduce, con física realista, cómo se comportaría un dron dentro de un entorno virtual, incluyendo lo que "vería" su cámara. ROS (Robot Operating System) es el middleware que conecta sensores, algoritmos y actuadores mediante mensajes. En este proyecto, como se explica en la sección 4, Gazebo+ROS tiene un papel más orientado a validar el sistema de vuelo y búsqueda que a generar el dataset de entrenamiento.

2.5 ¿Qué es un "mundo sintético"?

Un mundo sintético es un entorno 3D generado por software que imita una escena real. A diferencia de otros proyectos donde el objeto a detectar es rígido y fácil de sintetizar (por ejemplo, un panel solar dañado), representar personas de forma creíble es mucho más complejo — se explica en detalle en la sección 4.

2.6 ¿Qué son SITL y HITL?

- SITL (Software In The Loop): todo el sistema —incluido el propio piloto automático— se ejecuta como software, dentro del ordenador, contra un mundo simulado en Gazebo. No interviene ningún componente físico.
- HITL (Hardware In The Loop): un paso más cerca de la realidad — la controladora de vuelo física se conecta al ordenador y "cree" que está volando, recibiendo datos sensoriales simulados en lugar de sensores reales, pero ejecutando su firmware real sobre hardware real.

2.7 ¿Qué son Deep Learning e Inferencia?

Deep Learning (aprendizaje profundo) es la familia de técnicas de IA en la que se basa YOLO: redes neuronales con muchas capas que aprenden a reconocer patrones ajustando automáticamente millones de parámetros a partir de ejemplos etiquetados — ese proceso es el entrenamiento. Una vez entrenada, la red puede aplicarse a datos nuevos que nunca ha visto — a eso se le llama inferencia (detallado en la sección 9).

2.8 Formatos de exportación (ONNX y el formato del acelerador)

ONNX (Open Neural Network Exchange) es un formato estándar e independiente de la herramienta de entrenamiento, que permite "sacar" el modelo de Roboflow y llevarlo a otro entorno. Casi todos los aceleradores embarcados requieren, además, un paso de compilación propio (específico del fabricante del chip) que convierte ese ONNX a su formato nativo, optimizado para ejecutar más rápido. El nombre exacto de ese formato y de la herramienta de compilación depende del acelerador que use el proyecto.

3. Datasets reales disponibles para SAR

A diferencia de otros proyectos de detección de defectos donde el dato real es difícil de conseguir, la detección de personas desde el aire es un problema muy estudiado — existen datasets públicos, reales y de buena calidad, específicos para búsqueda y rescate:

Dataset	Qué aporta
SARD (Search And Rescue Dataset)	Específicamente creado para SAR: personas en terreno exterior/montañoso vistas desde dron
HERIDAL	Referencia en detección SAR desde UAV, terreno montañoso
VisDrone	Dataset amplio de detección de personas/objetos desde dron (no específico de SAR, pero útil para variedad)
C2A	Orientado a detección de víctimas ("casualties")
Okutama-Action	Vídeo aéreo de personas realizando acciones — útil si el proyecto incluye reconocimiento de actividad

Todos son importables a Roboflow (directamente desde Roboflow Universe, si están publicados ahí, o subiéndolos manualmente). El peso principal del dataset debería recaer en estas fuentes reales, no en datos sintéticos — es la estrategia inversa a la de un proyecto donde el defecto a detectar es difícil de fotografiar en la realidad.

4. Por qué los mundos sintéticos son más limitados aquí (y cómo usarlos igualmente)

4.1 La dificultad real: variabilidad, no fotorrealismo

El reto de representar personas en un mundo virtual no es tanto que “no se vean reales”, sino la enorme variabilidad de casos: de pie, tumbadas, semi-cubiertas por vegetación o escombros, con cualquier ropa, en cualquier postura. Esa variedad es mucho más difícil de sintetizar de forma útil que la de un objeto rígido con un número limitado de estados posibles.

4.2 Un matiz a favor: la altitud

En SAR real, los drones vuelan a altitudes donde una persona ocupa muy pocos píxeles en la imagen. A esa distancia, el detalle fino de un modelo 3D de persona importa mucho menos que su escala, color/contraste con el entorno, y pose general — un maniquí 3D razonable, visto desde 50-80 metros, resulta más creíble de lo que parecería de cerca.

4.3 Qué papel darle entonces a Gazebo en este proyecto

- Validación del sistema de vuelo y búsqueda: patrones de barrido, cobertura de cámara, planificación de misión, comportamiento del dron — aquí Gazebo aporta igual de bien que en cualquier otro proyecto, sin depender del realismo visual de las personas.
- Relleno de casos raros no cubiertos por los datasets públicos: por ejemplo, un tipo de terreno muy específico de la zona de estudio que no esté bien representado en SARD/HERIDAL/VisDrone. Aquí un mundo sintético dirigido a ese hueco concreto sí aporta valor, como aumentación dirigida, no como base del dataset.

Resumen de la estrategia recomendada Al contrario que en un proyecto donde el dato real es inaccesible (y por tanto lo sintético es la base), aquí el dato real es la base (datasets SAR públicos + capturas propias) y lo sintético es el complemento dirigido a huecos concretos y a la validación del sistema de vuelo, no del modelo de visión.

5. Construcción del dataset unificado en Roboflow

5.1 Crear un proyecto propio

Crea un proyecto de tipo "Object Detection" en Roboflow — el contenedor donde reunirás los datasets públicos de SAR, tus propias capturas, y (si procede) las imágenes sintéticas dirigidas a huecos concretos.

5.2 Importar los datasets reales de la sección 3

Importa los datasets públicos relevantes directamente a tu proyecto. Etiqueta cada imagen con un tag de origen al subirla (por ejemplo: source:sard, source:heridal, source:visdrone, source:propio, source:sintetico) — te permitirá filtrar más adelante si quieres comparar el efecto de cada fuente.

5.3 Unificar las etiquetas entre datasets (paso crítico)

Cada dataset público define sus propias clases, y no siempre coinciden. Es habitual encontrar variantes como person / Person / human / victim / casualty para lo que, en tu proyecto, debe ser una única clase unificada. Roboflow permite renombrar, fusionar o eliminar clases desde la gestión de clases del proyecto (Health Check → Classes, o "Preprocessing → Modify Classes"), sin tener que re-etiquetar nada a mano. Revisa igualmente una muestra de cada dataset fusionado — el criterio de qué cuenta como "persona visible" (por ejemplo, una persona muy parcialmente ocluida) puede variar entre datasets.

5.4 Añadir tus propias capturas y etiquetarlas

Sube tus propias imágenes/vídeos (por ejemplo, de vuelos de prueba) al mismo proyecto. Roboflow permite etiquetarlas directamente en su editor visual, usando las mismas clases ya unificadas.

5.5 La ventaja de Roboflow para etiquetar fotos nuevas

- Label Assist: una vez tienes un primer modelo entrenado (aunque sea preliminar), Roboflow puede pre-dibujar automáticamente los bounding boxes en las fotos nuevas — tu trabajo pasa de "dibujar" a "corregir", mucho más rápido.
- Especialmente útil aquí: como ya partes de varios datasets reales grandes (SARD, HERIDAL, VisDrone), el primer modelo preliminar para activar el Label Assist será razonablemente bueno desde el principio, más que en un proyecto que arranca sin ningún dato público disponible.

6. Validar el dataset antes de entrenar

Antes de entrenar, valida el dataset — un modelo entrenado sobre un dataset mal construido da métricas engañosas.

6.1 Qué comprobar

- Balance entre datasets de origen: si un único dataset (por ejemplo VisDrone, mucho más grande que SARD) domina el conjunto, el modelo puede terminar ajustado a las condiciones de ese dataset (tipo de terreno, altitud de vuelo) en vez de generalizar bien.
- Imágenes duplicadas o casi idénticas: revisa especialmente si combinas varios datasets que puedan compartir fuente de vídeo original.
- Calidad y consistencia de las anotaciones: revisa una muestra de cada fuente — criterios de qué

cuenta como "persona detectable" varían entre datasets (por ejemplo, alguien casi totalmente oculto por vegetación).

- Relevancia de las imágenes: descarta las que no correspondan al escenario de tu proyecto (por ejemplo, entornos urbanos muy distintos del terreno de estudio, si eso importa para tu caso).

6.2 División train / valid / test

Roboflow divide automáticamente en entrenamiento, validación y test al generar una versión (reparto habitual 70/20/10). Comprueba que los datasets minoritarios (por ejemplo, tus propias capturas) estén representados en los tres subconjuntos, no solo en entrenamiento.

7. Aumentación de datos (Data Augmentation)

La aumentación genera variaciones artificiales de las imágenes ya etiquetadas, multiplicando el tamaño efectivo del dataset. El objetivo es que el modelo generalice mejor ante condiciones que no están representadas en los datasets originales.

7.1 Aumentaciones recomendadas para este caso

Aumentación	Por qué tiene sentido aquí
Rotación / flip horizontal y vertical	Una persona puede aparecer en cualquier orientación según la trayectoria del dron
Brillo / exposición	Las condiciones de luz varían mucho entre vuelos, y SAR a menudo ocurre en condiciones no ideales
Desenfocado leve (blur)	Simula el desenfocado de movimiento a la velocidad de vuelo del dron
Ruido (noise)	Simula variaciones de sensor/compresión de vídeo
Escalado / zoom aleatorio	Simula personas vistas a distintas altitudes de vuelo, y por tanto distinto tamaño en píxeles

Aumentación especialmente relevante en SAR El escalado/zoom aleatorio merece más peso aquí que en otros proyectos: la altitud de vuelo real puede variar bastante según el terreno y la urgencia de la búsqueda, y el tamaño en píxeles de una persona cambia mucho con la altitud. Un dataset aumentado con variación de escala generaliza mejor a distintas altitudes operativas.

8. Entrenamiento del modelo en Roboflow

8.1 Elección de arquitectura

Para despliegue embarcado, interesan las versiones ligeras: YOLOv8/v9/v11 Nano o Small. Ofrecen un compromiso razonable entre precisión y velocidad de inferencia, necesario para procesar vídeo en tiempo real durante el vuelo.

8.2 Lanzar el entrenamiento

Roboflow gestiona automáticamente el transfer learning (partir de un modelo preentrenado y ajustarlo al dataset de personas), sin infraestructura propia de entrenamiento. Revisa hiperparámetros básicos si están expuestos (épocas, tamaño de imagen) — demasiadas épocas puede llevar a sobreajuste.

9. Evaluar el modelo: inferencia de validación y métricas

9.1 Qué es la inferencia (aplicado a esta fase)

- Inferencia de validación/evaluación (en Roboflow): se ejecuta sobre el conjunto de test, con el único propósito de medir el modelo antes de desplegarlo.
- Inferencia de producción (a bordo del dron): se ejecuta en vuelo, sobre vídeo en directo, con el modelo ya compilado y corriendo localmente — sin conexión a Roboflow ni a internet (sección 11).

9.2 Métricas a revisar

Métrica	Qué mide, en lenguaje llano
Precision (precisión)	De todo lo marcado como "persona", ¿qué porcentaje lo era realmente? Baja = muchas falsas alarmas.
Recall (exhaustividad)	De todas las personas realmente presentes, ¿qué porcentaje detectó el modelo? Bajo = personas reales que se escapan.
F1-Score	Media que combina precisión y recall en un solo número.
mAP@0.5	Precisión media, contando acierto si el rectángulo se solapa al menos un 50% con el real.
mAP@0.5:0.95	Versión más exigente, con solapamientos más estrictos — más informativa sobre precisión de localización.
Matriz de confusión	Qué se confunde con qué (por ejemplo, si el modelo confunde rocas o troncos con personas).

9.3 En qué fijarte especialmente en SAR

El recall lo es todo en este dominio En detección de defectos de un panel solar, priorizar recall sobre precisión ya era recomendable. En SAR, esa prioridad se vuelve prácticamente absoluta: un falso negativo (una persona real que el modelo no detecta) puede costar una vida; un falso positivo (una falsa alarma) cuesta, como mucho, el tiempo de un equipo de rescate comprobándolo. Ante la duda, ajusta el umbral de confianza del modelo hacia una mayor sensibilidad, aunque implique más falsas alarmas.

- Revisa el rendimiento desglosado por condición (tipo de terreno, si el dataset lo permite) — es más probable que falle en condiciones poco representadas (por ejemplo, personas parcialmente ocultas) que en casos claros.
- Overfitting (sobreajuste): si las métricas de entrenamiento son mucho mejores que las de validación/test, revisa duplicados entre datasets y el número de épocas.

10. Preparar el modelo para el dispositivo embarcado

10.1 Exportar desde Roboflow

Exporta el modelo entrenado desde Roboflow en formato ONNX — el paso común a cualquier hardware de destino.

10.2 Compilación para el acelerador embarcado

El fichero ONNX normalmente necesita pasar por la herramienta de compilación propia del fabricante del acelerador que use el proyecto, que cuantiza el modelo (reduce la precisión numérica de los cálculos para ejecutar más rápido y con menor consumo) y lo convierte a su formato nativo de

ejecución. El nombre concreto de esta herramienta y del formato resultante depende del hardware elegido — ajusta este paso al acelerador real del proyecto.

11. Qué corre a bordo del dron, y cómo se usa

11.1 Ficheros necesarios a bordo

Fichero	Para qué sirve
modelo compilado	El modelo ya optimizado para el acelerador embarcado — el "cerebro" entrenado
labels.txt / classes.yaml	La lista de nombres de clase, en el mismo orden que usó el modelo al entrenar
script de inferencia (Python)	El programa que orquesta todo: lee la cámara, llama al acelerador, procesa/envía resultados

11.2 El bucle de inferencia en vuelo

- OpenCV captura un fotograma de la cámara.
- OpenCV lo redimensiona/normaliza al formato de entrada del modelo.
- El acelerador embarcado ejecuta la inferencia sobre ese fotograma.
- El resultado bruto se decodifica (non-max suppression) para obtener la lista final de detecciones, con posición y confianza.
- El script registra cada detección junto con la posición GPS del dron en ese instante (vía telemetría), generando una alerta georreferenciada para el equipo de rescate.

11.3 Dónde ocurre realmente la inferencia

Importante para la memoria del proyecto Roboflow interviene únicamente en las fases 1-3 del pipeline (construcción del dataset, entrenamiento, exportación) — todo ello ocurre antes de volar, en la nube. Una vez el modelo está compilado y a bordo, el dron no depende de Roboflow ni de conexión a internet: toda la inferencia en vuelo se ejecuta localmente. Esto es especialmente relevante en SAR, donde las zonas de búsqueda a menudo no tienen cobertura de red fiable — el sistema debe funcionar de forma autónoma, sin depender de la nube durante la operación.

12. Resumen visual del pipeline completo

#	Paso	Herramienta	Dónde
1	Importar datasets SAR reales (SARD, HERIDAL, VisDrone, C2A) + unificar clases	Roboflow	Nube
2	Añadir capturas propias y etiquetarlas (Label Assist)	Roboflow	Nube
3	Validar el dataset (balance, duplicados, calidad)	Roboflow (Health Check)	Nube
4	Aumentar datos (rotación, brillo, blur, ruido, escala)	Roboflow	Nube

#	Paso	Herramienta	Dónde
5	Entrenar el modelo (YOLO Nano/Small)	Roboflow	Nube
6	Evaluar con métricas, priorizando recall	Roboflow	Nube
7	Exportar a ONNX	Roboflow	Nube
8	Compilar para el acelerador embarcado	Herramienta del fabricante	Tu PC
9	Copiar modelo + labels al dron	Manual / script	Tu PC → dron
10	Inferencia en tiempo real durante el vuelo	OpenCV + runtime del acelerador	A bordo, sin red

13. Checklist de recomendaciones

- Apóyate principalmente en datasets reales de SAR (SARD, HERIDAL, VisDrone, C2A) — a diferencia de otros dominios, aquí sí existen buenos datos reales públicos.
- Unifica las clases entre datasets ANTES de etiquetar tus propias fotos.
- Reserva Gazebo para validar el sistema de vuelo/búsqueda y para rellenar huecos concretos no cubiertos por los datasets públicos — no como base del dataset de entrenamiento.
- Da más peso a la aumentación por escala/zoom que en otros proyectos, para cubrir la variación de altitud de vuelo real.
- Prioriza recall sobre precisión de forma prácticamente absoluta — ajusta el umbral de confianza en consecuencia.
- Revisa el balance entre datasets de origen para que ninguno domine desproporcionadamente el conjunto.
- Prueba el modelo compilado con vídeo grabado antes de la primera prueba de vuelo real.
- Adapta la sección 10 (compilación) al acelerador embarcado real del proyecto — el concepto es el mismo que en otros proyectos similares, pero la herramienta concreta depende del hardware elegido.